Documentación técnica VectorIA · Módulo 3: ANN

VectorIA: Asistente Inteligente para la Vigilancia del Dengue en Costa Rica

Colegio Universitario de Cartago (CUC) · Proyecto 2 · Inteligencia Artificial

Integrantes: Mariana Méndez Pérez, Luis Diego Montero Vargas, Nadin Rojas López y Claret Rodríguez Jiménez

Profesor: Osvaldo González Chaves

Repositorio: github.com/Mari27MP/VectorIA

1. Propósito del módulo

Este módulo es el tercer componente de VectorIA. Su función es tomar el pronóstico de casos de dengue de las próximas 4 semanas (generado por el modelo LSTM del Módulo 2), las condiciones climáticas recientes y el resultado de la detección de Aedes aegypti (Módulo 1) para recomendar una acción de control vectorial a las autoridades de salud.

Se resuelve como un problema de clasificación multiclase con una red neuronal artificial (ANN) en TensorFlow/Keras. La herramienta es de apoyo a la vigilancia epidemiológica; no diagnostica dengue en personas.

1.1 Acciones recomendadas (clases de salida)

Clase	Significado
alerta_sanitaria	Los casos pronosticados superan ampliamente el canal endémico; requiere respuesta de nivel superior.
fumigacion_focalizada	Casos sobre el umbral y presencia detectada de Aedes aegypti; intervención dirigida en la zona.
eliminacion_criaderos	Condiciones de lluvia y calor que favorecen la reproducción del mosquito; campaña de eliminación de criaderos.
monitoreo_normal	Situación dentro de lo esperado; se continúa con la vigilancia rutinaria.

2. Datos

2.1 Origen y composición

Se utilizó el archivo vectoria_acciones.csv, ubicado en data/raw/. Contiene 2,060 filas (de 2017 a 2024) construidas sobre la serie real: 412 semanas × 5 escenarios. Es un dataset mixto: base real, etiquetas por reglas. La proporción real/simulada es la siguiente:

- Real: casos, clima y canal endémico (umbral endémico).
- Simulado: la predicción del LSTM (casos_pred_4sem), la detección de Aedes (aegypti_detectado) y la etiqueta (recomendacion).

2.2 Variables de entrada

Variable	Tipo	Descripción
casos_pred_4sem	Numérica	Casos pronosticados a 4 semanas (salida simulada del LSTM).
casos_umbral_endemico	Numérica	Umbral del canal endémico para esa semana.
ratio_casos	Derivada	casos_pred_4sem / casos_umbral_endemico. Se calcula en el notebook.
lluvia_14d_mm	Numérica	Lluvia acumulada en los últimos 14 días (mm).
temp_max	Numérica	Temperatura máxima (°C).
aegypti_detectado	Binaria	1 si la CNN detectó Aedes aegypti, 0 si no.

2.3 Reglas de etiquetado

La etiqueta se asignó aplicando estas reglas en orden; la primera que se cumple define la clase. Según el informe técnico, las etiquetas incluyen además un 3 % de ruido al azar:

Orden	Condición	Acción
1	Casos pred. > 2 × umbral endémico	alerta_sanitaria
2	Casos pred. > umbral endémico y Aedes aegypti detectado	fumigacion_focalizada
3	Lluvia 14 días > 80 mm y temp_max > 27 °C	eliminacion_criaderos
4	Cualquier otro caso	monitoreo_normal

3. Metodología

3.1 Preprocesamiento

- Variable derivada: se calcula ratio_casos a partir de los casos pronosticados y el umbral endémico.
- Codificación de etiquetas: LabelEncoder convierte las 4 acciones a enteros 0–3 (orden alfabético: alerta_sanitaria, eliminacion_criaderos, fumigacion_focalizada, monitoreo_normal).

- Escalado: StandardScaler (media 0, desviación 1), necesario porque las variables tienen escalas muy distintas (casos en cientos, temperatura en decenas, binaria 0/1).

3.2 Separación por semana (GroupKFold)

Cada semana aparece 5 veces. Si las filas se repartieran al azar, versiones de la misma semana quedarían en entrenamiento y prueba a la vez, y las métricas serían artificialmente optimistas. Por eso se usa GroupKFold con fecha_inicio_semana como grupo: una semana completa siempre queda de un solo lado. El notebook comprueba que existan 412 semanas distintas sobre 2,060 filas.

3.3 Arquitectura de la red

	Capa	Salida	Detalle
1	Input	6	Una neurona por variable de entrada.
2	Dense + ReLU	64	Primera capa oculta (448 parámetros).
3	Dense + ReLU	32	Segunda capa oculta (2,080 parámetros).
4	Dense + Softmax	4	Una probabilidad por acción (132 parámetros).

Total: 2,660 parámetros entrenables.

3.4 Entrenamiento

Parámetro	Valor
Optimizador	Adam
Función de pérdida	sparse_categorical_crossentropy (multiclase con etiquetas enteras)
Épocas	150
Tamaño de lote (batch)	32
Semilla	tf.keras.utils.set_random_seed(semilla) para resultados repetibles

3.5 Evaluación

Se aplicó validación cruzada de 5 particiones agrupada por semana. Las 412 semanas se reparten en 5 bloques; en cada vuelta 4 bloques entrenan y 1 prueba. Así cada semana se predice exactamente una vez con un modelo que nunca la vio, y las métricas finales se calculan sobre las 2,060 filas. El escalador se ajusta únicamente con los datos de entrenamiento de cada vuelta para no filtrar información del bloque de prueba.

Se compararon dos configuraciones:

- **Una red:** semilla 1, se toma la clase de mayor probabilidad.

- **3 redes:** semillas 1, 2 y 3; se promedian sus probabilidades y se toma la clase de mayor valor.

4. Resultados

El porcentaje para el proyecto es Precision / Recall ≥ 85 % por clase.

Ambas se cumplen en todas las clases.

4.1 Una sola red

Clase	Precision	Recall	F1-score	Support
alerta_sanitaria	0.95	0.92	0.94	379
eliminacion_criaderos	0.90	0.85	0.88	321
fumigacion_focalizada	0.91	0.85	0.88	147
monitoreo_normal	0.95	0.98	0.96	1,213
Accuracy			**0.94**	2,060
Macro avg	0.93	0.90	0.91	2,060
Weighted avg	0.94	0.94	0.94	2,060

4.2 Ensamble de 3 redes

Clase	Precision	Recall	F1-score	Support
alerta_sanitaria	0.97	0.92	0.94	379
eliminacion_criaderos	0.88	0.88	0.88	321
fumigacion_focalizada	0.90	0.85	0.87	147
monitoreo_normal	0.95	0.98	0.96	1,213
Accuracy			0.94	2,060
Macro avg	0.93	0.91	0.92	2,060
Weighted avg	0.94	0.94	0.94	2,060

4.3 Análisis

- **Cumplimiento del umbral:** el valor mínimo observado es 0.85 (recall de eliminacion_criaderos y fumigacion_focalizada con una red, y de fumigacion_focalizada con el ensamble), por lo que se alcanza el 85 % exigido, aunque con margen estrecho en esas dos clases.
- **Mejor desempeño en la clase mayoritaria:** monitoreo_normal obtiene F1 = 0.96 con 1,213 ejemplos; es la clase con más datos para aprender.

- **Clase más difícil:** fumigacion_focalizada tiene solo 147 ejemplos (7.1 %) y su recall es 0.85. Además depende de dos condiciones simultáneas (casos sobre el umbral y Aedes detectado), por lo que sus fronteras se confunden con las de alerta_sanitaria y monitoreo_normal.
- **Una red vs. ensamble:** la exactitud global es la misma (0.94) y el macro F1 mejora apenas de 0.91 a 0.92. El ensamble sube el recall de eliminacion_criaderos (0.85 → 0.88) a costa de precisión (0.90 → 0.88). La diferencia es pequeña.

5. Modelo final

El modelo final es una sola red, entrenada con todas las semanas (semilla 1), con un `StandardScaler` ajustado sobre todos los datos.

5.1 Archivos generados

Archivo (en `models/`)	Contenido
`modelo_ann_acciones.keras`	Red neuronal entrenada.
`modelo_ann_acciones_preprocesadores.pkl`	Diccionario con `scaler` (StandardScaler), `label_encoder` (LabelEncoder) y `features`

8. Conclusiones

- La ANN cumple la meta del proyecto: precision y recall entre 0.85 y 0.98 en las cuatro acciones, con una exactitud de 0.94 y un F1 macro de 0.91 en validación cruzada agrupada por semana.
- Las clases más difíciles son fumigacion_focalizada y eliminacion_criaderos, que quedan justo en 0.85 de recall. El ensamble de 3 redes casi no mejora el resultado, por lo que el modelo final es una sola red entrenada con todos los datos.